Министерство образования Республики Беларусь

Учреждение образования «Белорусский государственный университет информатики и радиоэлектроники»

Факультет компьютерных систем и сетей

Кафедра электронных вычислительных машин

Дисциплина: Операционные системы и системное программирование

К ЗАЩИТЕ ДОПУСТИТЬ

_____ Б. В. Никульшин

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

к курсовому проекту

на тему

«Утилита контроля появления дубликатов в файловой системе с заменой их на жесткие ссылки и протоколирования фактов замены»

БГУИР КП 1-40 02 01 002 ПЗ

Студент: Власов Р. Е

Руководитель: старший преподаватель кафедры ЭВМ Л.П. Поденок

Минск 2025

Учреждение образования
«Белорусский государственный университет информатики
и радиоэлектроники»

Факультет компьютерных систем и сетей

УТВЕРЖДАЮ
Заведующий кафедрой ЭВМ

_____
(подпись)
_____ 20 г.

З А Д А Н И Е
по курсовому проектированию

Студенту Власову Роману Евгеньевичу

1. Тема проекта Утилита контроля появления дубликатов в файловой системе с заменой их на жесткие ссылки и протоколирования фактов замены

2. Срок сдачи студентом законченного проекта 2 июня 2025 г.

3. Исходные данные к проекту:

1. Операционная система – Fedora Linux (KDE Plasma);

2. Язык программирования – C (ISO/IEC 9899-2011) с компилятором gcc;

3. Сборка проекта должна выполняться с помощью утилиты make

4. Файлы в составе проекта должны контролироваться git;

5. При отборе дубликатов необходимо определять сигнатуры и MIME-типы файлов, при их несовпадении – исключать возможность дублирования.

4. Содержание расчетно-пояснительной записки (перечень вопросов, которые подлежат разработке)

1. Лист задания.
2. Введение.
3. Обзор методов и алгоритмов решения поставленной задачи.
4. Обоснование выбранных методов и алгоритмов.
5. Описание программы для программиста.
6. Описание алгоритмов решения задачи.
6. Руководство пользователя.

7. Заключение.
8. Литература.
9. Приложения.

5. Перечень графического материала (с точным обозначением обязательных чертежей и графиков)
1. Схема алгоритма функции *main()* (формат А4).
2. Схема алгоритма функции *lookup_duplicate* (формат А4).
3. Схема алгоритма сравнения *compute_md5* (формат А4).
4. Ведомость документов (формат А4).

6. Консультант по проекту (с обозначением разделов проекта) Л.П. Поденок

7. Дата выдачи задания 26.12.2024

8. Календарный график работы над проектом на весь период проектирования (с обозначением сроков выполнения и трудоемкости отдельных этапов):
разделы 1, 2 к 26.01.2025 – 20 %;
раздел 3 к 19.02.2025 – 20 %;
раздел 4 к 19.03.2025 – 30 %;
раздел 5 к 12.04.2025 – 10 %;
оформление пояснительной записки к 22.05.2025 - 20 %;
Защита курсового проекта с 12.06 по 02.07.2025.

РУКОВОДИТЕЛЬ ст. преподаватель каф ЭВМ Поденок Л.П
(подпись)

Задание принял к исполнению 26.12.2024
(дата и подпись студента)

СОДЕРЖАНИЕ

ВВЕДЕНИЕ

Современные файловые системы часто сталкиваются с проблемой наличия идентичных файлов, что приводит к нерациональному расходованию дискового пространства и снижению общей производительности системы. Инструменты для обнаружения и устранения таких дублированных файлов являются ключевыми для эффективной организации файловых хранилищ.

Одним из эффективных способов решения данной задачи является использование жёстких ссылок — особого вида файловых ссылок, благодаря которым несколько записей могут ссылаться на один и тот же физический файл на диске, исключая тем самым необходимость хранения нескольких копий данных. Это позволяет существенно экономить дисковое пространство и одновременно повышать производительность за счёт уменьшения нагрузки на файловую систему при обработке повторяющихся данных. Кроме того, такой подход минимизирует вероятность ошибок, возникающих при ручном удалении или перемещении файлов, и обеспечивает поддержание целостности и согласованности данных даже при интенсивных изменениях в файловой системе.

1 ОБЗОР ЛИТЕРАТУРЫ

1.1 Обзор предметной области

Проблема избыточного копирования файлов знакома как частным пользователям, так и крупным организациям. По мере роста объёмов данных на серверах и персональных устройствах одни и те же файлы нередко оказываются сохранёнными в разных каталогах, что приводит к неоправданному занятию дискового пространства и замедлению работы системы. В условиях ограниченных ресурсов — будь то ёмкость хранилища или вычислительная мощность — грамотная организация хранения данных становится приоритетом.

Одним из наиболее надёжных приёмов оптимизации хранилищ является применение жёстких ссылок. Жёсткая ссылка позволяет «привязать» несколько записей к одному и тому же блоку на диске, избавляясь от необходимости хранения повторяющихся копий, при этом сохраняя прямой доступ к содержимому.

В отличие от символических ссылок, жёсткие ссылки не теряют работоспособности при перемещении или удалении исходного файла — до тех пор, пока существует хотя бы одна ссылка на данные, они остаются доступными. Данная технология поддерживается многими файловыми системами: HFS+ и APFS на macOS, ext4 в Linux, NTFS в Windows и другими, что делает её универсальным инструментом для повышения эффективности использования дискового пространства.

Не менее важным элементом подобных решений является ведение журнала операций по замене дубликатов жёсткими ссылками. Протоколирование обеспечивает:

– фиксацию сведений о найденных дубликатах и выполненных преобразованиях;

– регистрацию ошибок и исключительных ситуаций

– возможность восстановления исходного состояния при необходимости;

– гибкую настройку уровня детализации логов

1.2 Анализ аналогов программного средства

В рамках разработки утилиты контроля появления дубликатов в файловой системе с заменой их на жесткие ссылки и протоколирования фактов замены важно изучить существующие программные средства, выполняющие аналогичные функции. Это позволяет не только понимать текущие технологии и подходы, но и выявить их сильные и слабые стороны, что поможет создать более эффективный и функциональный инструмент. В этом разделе рассмотрены наиболее известные и широко используемые аналоги.

1.2.1 fdupes

fdupes – это простая консольная утилита, которая находит дубликаты файлов на основе их содержимого. Она позволяет рекурсивно сканировать директории и взаимодействовать с пользователем для удаления дубликатов.

Программа имеет следующие возможности:

– поиск дубликатов файлов на основе сравнения хэш-сумм и последующего побайтового сравнения для точности;

– поддержка рекурсивного поиска по каталогам;

– поддержка удаления дубликатов и интерактивного выбора действий. Недостатки приложения:

– отсутствие продвинутых настроек поиска, таких как фильтрация по типам файлов или времени последнего изменения;

– ограниченная функциональность в плане протоколирования операций.

1.2.2 Duplicate File Finder

Duplicate File Finder– утилита, ориентированная на поиск и управление дубликатами файлов с продвинутыми возможностями и графическим интерфейсом. Интерфейс и частичный функционал изображены на рисунке 1.2.2.

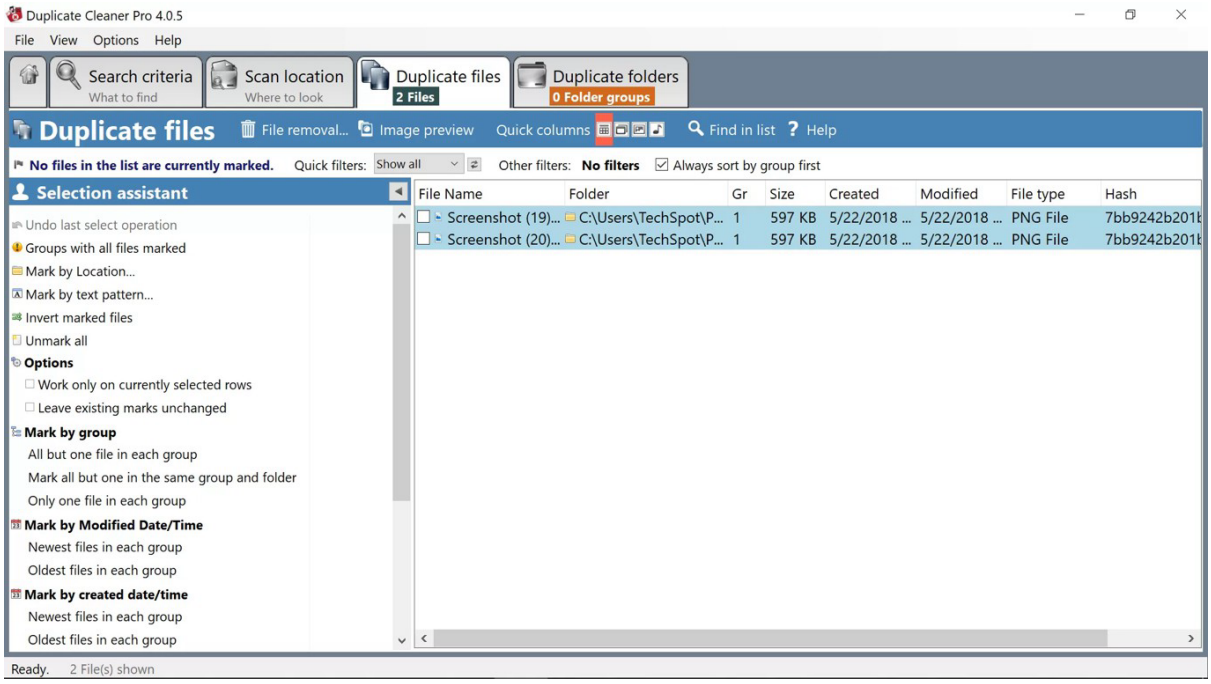

Рисунок 1.2.2 – Скриншот программы Duplicate Cleaner

Возможности и преимущества утилиты:

– поддерживает поиск дубликатов по имени, размеру, содержимому и метаданным;

– подробный и настраиваемый интерфейс для управления результатами поиска;

– включает возможность предварительного просмотра файлов, настройки фильтров и отчеты;

– профессиональная версия позволяет заменять дубликаты на жесткие ссылки;

– детализированный поиск и управление результатами,

возможность создания отчетов.

Ограничения программы:

– некоторые расширенные возможности доступны только в платной версии.

1.2.3 Duff

Duff — это мощная и быстрая утилита с открытым исходным кодом для поиска дубликатов файлов и оптимизации дискового пространства. Она поддерживает Linux, Windows и macOS, и предоставляет как графический интерфейс (GUI), так и возможность использования через командную строку (CLI). Интерфейс и частичный функционал изображен на рисунке 1.2.3.

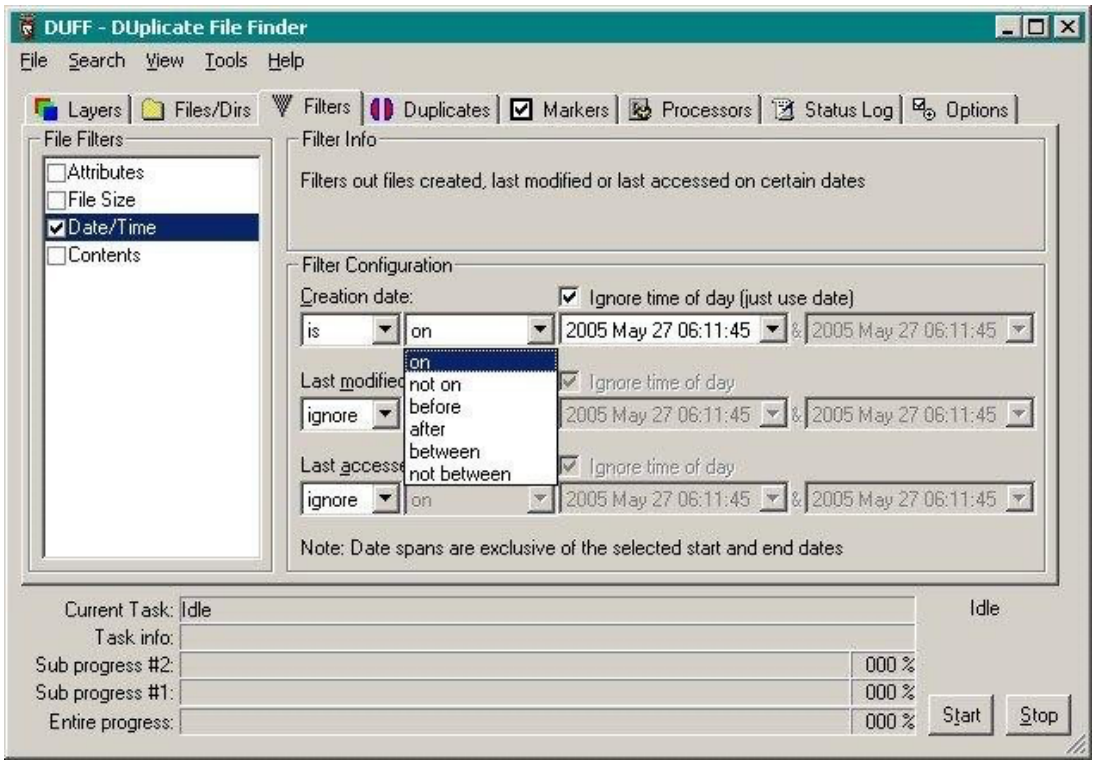

Рисунок 1.2.3 – Скриншот программы Duff

Основные функции Duff:

– поиск дубликатов файлов на основе хеширования файлов (SHA-1);

– помогает удалить ненужные каталоги, которые остались после удаления файлов;

– позволяет выявить файлы, занимающие больше всего места на диске;

– выявляет и удаляет битые символические ссылки.

Недостатки утилиты:

– не поддерживает выборочную сортировку результатов;

– ограниченная возможность предпросмотра.

1.2.4 rdfind

rdfind – CLI-инструмент, специализирующийся на поиске дубликатов и их удалении. Он создает текстовый отчет о найденных дубликатах и может быть настроен для автоматической замены дубликатов на жесткие ссылки. Rdfind эффективно управляет дубликатами, но ограничен в плане гибкости настроек, и у него отсутствует графический интерфейс.

Преимущества rdfind:

– поддержка более точного алгоритма хэширования (SHA-1);

– возможность гибкой настройки поиска с фильтрацией определенных каталогов и файлов;

– простота интеграции в автоматические скрипты и системы управления файлами.

Недостатки rdfind:

– ограниченная поддержка протоколирования операций — информация об изменениях сохраняется минимально;

– нет функции восстановления файлов после замены на жесткие ссылки.

1.3 Постановка задачи

Анализ существующих решений показал, что они включают множество функций, реализация которых выходит за рамки курсового проекта. В связи с этим для выполнения в течение семестра были отобраны ключевые возможности:

– ввод директории пользователем;

– организация фонового процесса для проверки файлов на дубликаты;

– возможность корректного завершения фонового процесса;

– замена найденных дубликатов жёсткими ссылками;

– логирование результатов фонового процесса;

– постоянный мониторинг файловой системы на предмет появления новых дубликатов.

2 ФУНКЦИОНАЛЬНОЕ ПРОЕКТИРОВАНИЕ

В данном разделе описывается функционирование и структура разрабатываемого приложения.

2.1 Структура входных и выходных данных

Входные данные передаются через аргументы командной строки:

– `kill`. При наличии этого аргумента программа читает `PID` из файла блокировки `(LOCK_FILE)` и посылает соответствующему процессу сигнал `SIGTERM` для корректного завершения процесса.

– путь к каталогу для сканирования. Если указан один аргумент без ключа `-kill`, он рассматривается как абсолютный или относительный путь к директории, которую следует обходить в поисках дубликатов. `(DEFAULT_DIR).`

Если аргументы не переданы, утилита по умолчанию сканирует каталог пользователя `(DEFAULT_DIR),` заданный через макрос (обычно `$HOME).`

Выходные данные — это файл журнала `(LOG_FILE),` в который приложение записывает информацию о своей работе:

– метки времени и уровень сообщений `(INFO / ERROR);`

– операции запуска и завершения каждого прохода сканирования;

– информация о найденных и заменённых дубликатах (какой файл был заменён на жёсткую ссылку);

– сообщения об ошибках при открытии каталогов, файлов или при создании ссылок.

2.2 Описание работы функций

2.2.1 Функция `main`

Функция принимает параметры:

– `int argc` — число аргументов командной строки (включая имя программы);

– `char *argv[]` — массив строк, где `argv[0]` — путь к исполняемому файлу, а `argv[1…argc–1]` — переданные пользователем параметры.

Возвращаемое значение: функция возвращает либо 0 при успешном завершении работы программы, либо EXIT_FAILURE в случае ошибки.

В начале выполнения main считывает из окружения переменную `HOME` и формирует на её основе пути к каталогу кеша, файлам логирования, блокировки и двоичному журналу. Если обнаружен аргумент - kill, вызывается функция остановки активного процесса и программа завершается.

В противном случае создаётся нужный каталог кеша, проверяется отсутствие уже запущенного экземпляра через файл блокировки, настраиваются обработчики сигналов. Затем создаётся `lock`-файл с текущим `PID`, после чего в бесконечном цикле с паузой последовательно выполняются: запись в лог сообщения о старте обхода, очистка двоичного журнала, рекурсивный просчёт `MD5` и замена дубликатов жёсткими ссылками, и запись в лог информации об окончании прохода.

2.2.2 Функция `log_message`

Функция принимает два параметра: строку уровня сообщения (`INFO` или `ERROR`) и собственно текст сообщения. Она открывает лог-файл в режиме добавления, формирует метку времени в заданном формате даты,

затем записывает в файл строку вида [timestamp] [level] message. При невозможности открыть файл для записи производится запись об ошибке через syslog, выполняется очистка временных файлов и программа завершается, что гарантирует консистентность lock-файла и бинарного журнала.

2.2.3 Функция make_path

Функция make_path служит для безопасного формирования строковых путей: она принимает указатель на буфер dst и его размер dstsz, формат строки fmt и строку home, содержащую путь к домашнему каталогу. Внутри один вызов snprintf(dst, dstsz, fmt, home) заполняет буфер корректной NUL-терминированной строкой. Возвращаемое значение отсутствует.

2.2.4 Функция ensure_singleton

Получает путь к файлу блокировки и пытается создать его с флагами O_CREAT, O_EXCL, O_WRONLY. Если файл уже существует (errno == EEXIST), она печатает в stderr сообщение: уже запущен и возвращает –1; при других ошибках использует perror, также возвращая –1. В случае успешного создания сразу закрывает дескриптор и удаляет этот пробный lock-файл (чтобы не мешал настоящему), возвращая 0.

2.2.5 Функция create_lock_file

При старте демона эта функция заново создаёт lock-файл (флаги O_WRONLY,O_CREAT,O_TRUNC), записывает в него PID процесса через snprintf и write и возвращает открытый файловый дескриптор. В случае ошибки открытия возвращает –1 (после вызова perror("lock create")).

2.2.6 Функция kill_running

Для аргумента -kill используется kill_running, которая открывает файл блокировки в режиме чтения, извлекает из него целочисленный PID через fscanf и отправляет этому процессу сигнал SIGTERM. В случае успеха печатает deduplar: отправлен SIGTERM “pid”, иначе вызывает perror. Если открыть файл не удалось, выводит deduplar: процесс не найден.

2.2.7 Функция reset_bin

Чтобы каждый цикл начинался очищенным, reset_bin открывает двоичный журнал g_bin_path в режиме wb (что обнуляет его содержимое) и тут же закрывает файл. Если открытие не удалось, функция silently пропускает ошибку.

2.2.8 Функция same_inode

Для определения того, принадлежат ли два файла одной физической сущности, функция same_inode принимает пути a и b, выполняет stat для каждого и сравнивает поля st_dev и st_ino. Если оба вызова stat успешны и поля совпадают, возвращается ненулевое значение (истина), иначе — 0.

2.2.9 Функция write_bin

Каждый обнаруженный уникальный файл записывается в бинарный журнал функцией write_bin, которой передаётся структура file_info_t, содержащая длину пути, сам путь, размер файла и MD5-хеш. Открытие g_bin_path в режиме ab при сбое вызывает log_msg("ERROR", ...), cleanup() и завершение процесса. При успехе поля структуры последовательно записываются вызовами fwrite, после чего файл закрывается.

2.2.10 Функция `lookup_duplicate`

Поиск ранее встреченных файлов выполняет lookup_duplicate, открывающая журнал `g_bin_path` в режиме `rb`. В цикле считываются сначала длина пути, затем сама строка пути (с выделением памяти), размер файла и `MD5`-хеш. Если размер и хеш совпадают с тем, что ищется, файл закрывается, и возвращается указатель на строку с путём дубликата (`caller` обязан освободить память).

Если записи заканчиваются, функция закрывает файл и возвращает `NULL`.

2.2.11 Функция `md5_file`

Вычисление контрольной суммы организовано в `md5_file`, принимающей путь `path` и буфер `out` длиной `HASH_TEXT_LEN`. Сначала создаётся контекст `OpenSSL` через `EVP_MD_CTX_new`, затем файл открывается в режиме `rb`. Если не удалось ни открыть файл, ни инициализировать контекст, фиксируется ошибка, контекст и/или файл закрываются, и функция возвращает управление вызывающему. При успешной инициализации выполняется `EVP_DigestInit_ex(ctx, EVP_md5(), NULL)`, затем в цикле считываются блоки по 4096 байт, передавая их в `EVP_DigestUpdate`. Финализация `(EVP_DigestFinal_ex)` заполняет буфер байт хеша и длину, контекст освобождается, файл закрывается, и каждый байт преобразуется в две шестнадцатеричные цифры через `sprintf`, с установкой завершающего нуля.

2.2.12 Функция `traverse`

Рекурсивный обход директорий выполняет `traverse`, открывающая каталог через `opendir(dir)`. Если открыть не удалось, вызывается `log_msg` с ошибкой и возвращается. Для каждой записи формируется путь, вызывается `stat`. Если это вложенная директория, `traverse` вызывается рекурсивно, иначе если это обычный файл, создаётся структура `file_info_t`

с заполнением размера, длины пути и пути (через strdup), затем вычисляется MD5. После этого вызывается lookup_duplicate; при отсутствии дубликата — write_bin, при обнаружении дубликата и несовпадающем inode сначала удаляется текущий файл (unlink), затем создаётся жёсткая ссылка link(dup, fi.path), а результат замены логируется через log_msg; при ошибке создания ссылки пишется log_msg с ошибкой. Память под пути освобождается, и, если был дубликат, освобождается указатель dup. По завершении обхода каталог закрывается через closedir.

2.2.13 Функция cleanup

Удаление временных артефактов и завершение работы процесса выполняет cleanup, закрывающая дескриптор g_lock_fd, если он ≥ 0, и удаляющая файлы g_lock_path и g_bin_path через unlink.

2.2.14 Функция on_signal

Обработчик сигналов on_signal принимает номер сигнала sig, записывает в лог через log_msg соответствующее сообщение: для SIGINT и SIGTERM уровень "INFO", для SIGSEGV и SIGABRT — "ERROR". После записи выполняет cleanup() и завершает процесс кодом EXIT_SUCCESS для нормальных сигналов и EXIT_FAILURE для аварийных.

3 РАЗРАБОТКА ПРОГРАММЫ

В данном разделе рассмотрены описания алгоритмов функций, используемых в программе.

3.1 Алгоритм функции `main`

Шаг 1. Начало.

Шаг 2. Условный оператор: если переменная среды задана, то шаг 3, иначе переход к шагу 15.

Шаг 3. Сформировать рабочие пути: каталог кэша, лог-файл, `lock`-файл, бинарный журнал.

Шаг 4. Условный оператор: если передан ключ `-kill`, то переход к шагу 5, иначе к шагу 6.

Шаг 5. Прочитать `PID` из `lock`-файла и попытаться завершить связанный процесс; затем перейти к шагу 15.

Шаг 6. Создать при необходимости каталог кеша.

Шаг 7. Тест-создание временного `lock`-файла, чтобы убедиться, что приложение ещё не запущено и у есть права записи; если тест не прошёл → шаг 15.

Шаг 8. Определить директорию для сканирования (параметр пользователя или корневой каталог).

Шаг 9. Назначить обработчики системных сигналов.

Шаг 10. Перевести процесс в фон (двойной `fork`), создать постоянный `lock`-файл, записать в него `PID`.

Шаг 11. Зафиксировать в логе начало сканирования; очистить бинарный журнал файлов.

Шаг 12. Рекурсивно просканировать назначенную директорию, при необходимости заменяя дубликаты жёсткими ссылками.

Шаг 13. Записать в логе завершение прохода.

Шаг 14. Приостановиться на заданный интервал и вернуться к шагу 11.

Шаг 15. Конец.

3.2 Алгоритм функции `lookup_duplicate`

Шаг 1. Начало.

Шаг 2. Открыть бинарный журнал в режиме чтения; если отсутствует, то возвращается NULL и переход на шаг 11, если присутствует, то переход к шагу 4.

Шаг 3. Прочитать 32-битную длину следующего сохранённого пути.

Шаг 4. Проверить, удалось ли прочитать длину, если нет, то переход на шаг 6, если да, то переход на шаг 7.

Шаг 5. Закрыть файл и вернуть NULL (достигнут конец журнала либо ошибка).

Шаг 6. Выделить память под строку указанной длины и прочитать сам путь.

Шаг 7. Считать из журнала размер файла и его MD5-хэш.

Шаг 8. Условный оператор: сравнить полученные размеры и MD5 с искомыми значениями, если совпадают, то шаг 9, а если не совпадают, то шаг 10.

Шаг 9. Закрыть файл и вернуть указатель на найденный путь и переход к шагу 12.

Шаг 10. Освободить выделенную память и перейти к следующей записи (вернуться к Шагу 4).

Шаг 11. Конец.

3.3 Алгоритм функции `Compute_md5`

Шаг 1. Начало.

Шаг 2. Инициализировать буфер для хранения `MD5`-хеша и переменную его длины.

Шаг 3. Создание контекст хеширования и открытие необходимого файла в бинарном режиме.

Шаг 4. Условный оператор: если ресурсы не получены, то занести ошибку в лог и завершить функцию.

Шаг 5. Запустить подсчёт хеша и считать очередной блок данных из файла в оперативную память.

Шаг 6. Передача считанного блока в MD5-контекст для обновления хеша.

Шаг 7. Условный оператор: Указатель на конце файла. Если да, то переход к шагу 8, иначе к шагу 6.

Шаг 8. Финализация вычислений и запись готового двоичного хеша в буфер.

Шаг 9. Закрытие файла, освобождение MD5-контекста.

Шаг 10. Преобразование данных из буфера в строку в виде шестнадцатеричных символов.

Шаг 11. Вернуть указатель на сформированную строку.

Шаг 12. Конец.

4 РУКОВОДСТВО ПОЛЬЗОВАТЕЛЯ

4.1 Системные требования

Для запуска данной программы необходим персональный компьютер с установленной любой UNIX-системой подобной Linux, MacOS. На нем так же должен быть установлен пакет с библиотекой OpenSSL.

4.2 Использование приложения

Для запуска процесса необходимо предварительно его скомпилировать в консоли с помощью файла `make`. Для файла `make` установлены следующие команды:

– `make` — компилирование исходных фалов и создание необходимых директорий;

– `make install` — копирует файл в директорию для поиска исполняемых файлов;

– `make uninstall` — удаляет файл из директории поиска исполняемых файлов;

– `make clean` — очищает `build` и другие связанные с приложением директории;

Пример компиляции приложения:

```
Roman@MacBook-Pro-Roman deduplar % make
mkdir -p build/ /Users/Roman/Library/Caches/deduplar
clang -o build/deduplar src/deduplar.c -Wall -Wextra -
pedantic - std=c11 -I/opt/homebrew/opt/openssl@3/include -
L/opt/homebrew/opt/openssl@3/lib -Wl,-
rpath,/opt/homebrew/opt/openssl@3/lib -lssl -lcrypto
\DLOG_FILE=\"/Users/Roman/Library/Caches/deduplar/deduplar.log\"\
  DLOCK_FILE=\"/Users/Roman/Library/Caches/deduplar/deduplar.lock
  DBIN_FILE=\"/Users/Roman/Library/Caches/deduplar/deduplar.bin\"
  -DSCAN_INTERVAL=20
```

```
Roman@MacBook-Pro-Roman deduplar % make install
sudo install -m 755 build/deduplar
/usr/local/bin/deduplar
```

После компиляции необходимо выполнить следующую команду:

```
deduplar [директория]
```

При отсутствии аргумента сканируется root директория.

После выполнения данной команды, программа создаст фоновый процесс, который будет проверять файлы и заменять дубликаты на жёсткие ссылки.

Пример выполнения данной команды:

```
Roman@MacBook-Pro-Roman deduplar % deduplar ~/Desktop/test-
deduplicator
```

Для проверки корректности программы можно просмотреть ссылки файлов всего каталога при помощи:

```
Roman@MacBook-Pro-Roman deduplar % ls -li ~/Desktop/test-
deduplicator
total 120
265792100 -rw-r--r--@ 3 Roman  staff  12413 May 11 23:19
file1.c
265792100 -rw-r--r--@ 3 Roman  staff  12413 May 11 23:19
file2.c
265792100 -rw-r--r--@ 3 Roman  staff  12413 May 11 23:19
file3.c
265792084 -rw-r--r--  3 Roman  staff  15 May 11
23:19 fileA.txt
265792084 -rw-r--r--  3 Roman  staff  15 May 11
23:19 fileB.txt
265792084 -rw-r--r--  3 Roman  staff  15 May 11
23:19 fileC.txt
```

Для остановки фонового процесса необходимо прописать с командной строке следующую команду:

```
deduplar -kill
```

После этой команды, если фоновый процесс существовал, он будет отключен.

```
Roman@MacBook-Pro-Roman deduplar % deduplar -kill
deduplar: Отправлен SIGTERM 63447 для завершения
```

В случае, если фоновый процесс уже запущен, то при попытке создания нового процесса в консоль будет выведена ошибка. В то же время, если процесс отсутствует, то при попытке его удаления так же будет выведена ошибка:

```
Roman@MacBook-Pro-Roman deduplar % deduplar ~/Desktop/test-deduplicator
deduplar: уже запущен
Roman@MacBook-Pro-Roman deduplar % deduplar -
kill deduplar: Отправлен SIGTERM 63447 для
завершения Roman@MacBook-Pro-Roman deduplar %
deduplar -kill deduplar: Процесс не найден
```

Для получения результатов выполнения программы необходимо зайти в директорию:

```
/var/root/Library/Caches/deduplar
```

И найти там файл `deduplar.log`. Либо ввести команду:

```
tail -n +1 -~/Library/Caches/deduplar/deduplar.log.
```

В него записываются все основные события приложения такие как начало и конец обработки директории, удаление и замена файлов на ссылки, а так же все возможные варианты ошибок и остановок процесса.

Пример log-файла:

```
[2025-05-11 23:19:20] [INFO] Начало обхода
/Users/Roman/Desktop/test-deduplicator
[2025-05-11 23:19:20] [INFO] Заменен
/Users/Roman/Desktop/test- deduplicator/fileC.txt с жесткой
ссылкой на
/Users/Roman/Desktop/test-deduplicator/fileB.txt
[2025-05-11 23:19:20] [INFO] Заменен
/Users/Roman/Desktop/test- deduplicator/fileA.txt с жесткой
```

```
ссылкой на
/Users/Roman/Desktop/test-deduplicator/fileB.txt
[2025-05-11 23:19:20] [INFO] Заменен
/Users/Roman/Desktop/test- deduplicator/file1.c с жесткой
ссылкой на
/Users/Roman/Desktop/test-deduplicator/file2.c
[2025-05-11 23:19:20] [INFO] Заменен
/Users/Roman/Desktop/test- deduplicator/file3.c с жесткой
ссылкой на
/Users/Roman/Desktop/test-deduplicator/file2.c
[2025-05-11 23:19:20] [INFO] Завершено, повтор через 20 сек
[2025-05-11 23:19:40] [INFO] Начало обхода
/Users/Roman/Desktop/test-deduplicator
[2025-05-11 23:19:40] [INFO] Завершено, повтор через 20 сек
[2025-05-11 23:20:27] [INFO] SIGTERM получен
```

Для удаления программы необходимо ввести команду:

```
make uninstall
```

Список команд для тестирования программы:

```
mkdir -p ~/Desktop/test-
deduplicator cd ~/Desktop/test-
deduplicator

echo "duplicate test" >
fileA.txt cp fileA.txt
fileB.txt
cp fileA.txt fileC.txt

cp /Users/Roman/Documents/deduplar/src/deduplar.c
file1.c cp file1.c file2.c
cp file1.c file3.c

deduplar ~/Desktop/test-deduplicator

tail -n +1 -f ~/Library/Caches/deduplar/deduplar.log

ls -li ~/Desktop/test-deduplicator
deduplar -kill
```

ЗАКЛЮЧЕНИЕ

В результате работы над данным курсовым проектом было разработано работоспособное приложение со своим набором функций и интерфейсом.

Работа была разделена на такие этапы, как анализ существующих аналогов, литературных источников, постановка требований к проектируемому программному продукту, системное и функциональное проектирование, разработка программных модулей и тестирование проекта. После успешного прохождения всех этапов разработки получено надёжно функционирующее приложение.

Созданная утилита выполняет следующие функции:

– ввод пользователем директории для сканирования;

– запуск фонового процесса для обнаружения дубликатов;

– корректное завершение или принудительное удаление фонового процесса;

– замена найденных дубликатов на жёсткие ссылки;

– логирование результатов фонового процесса;

– постоянный контроль за появлением дублирующихся файлов в файловой системе.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1]. RFC 1321. The MD5 Message-Digest Algorithm - спецификация алгоритма MD5 [Электронный ресурс]. – Режим доступа: https://www.ietf.org/rfc/rfc1321.txt.

[2]. OpenSSL Cookbook– пособие по использованию OpenSSL EVP API [Электронный ресурс]. – Режим доступа: https://www.feistyduck.com/books/openssl-cookbook/

[3]. Хабр – информационный портал для разработчиков [Электронный ресурс]. – Режим доступа: https://habr.com/ru.

[4]. Apple Developer Documentation: Daemons and Services Programming Guid [Электронный ресурс]. – Режим доступа: https://developer.apple.com/library/archive/documentation/MacOSX/Conceptual/BPSystemStartup/Chapters/Introduction.html

ПРИЛОЖЕНИЕ А

(Обязательное)

Блок-схема алгоритма функции main

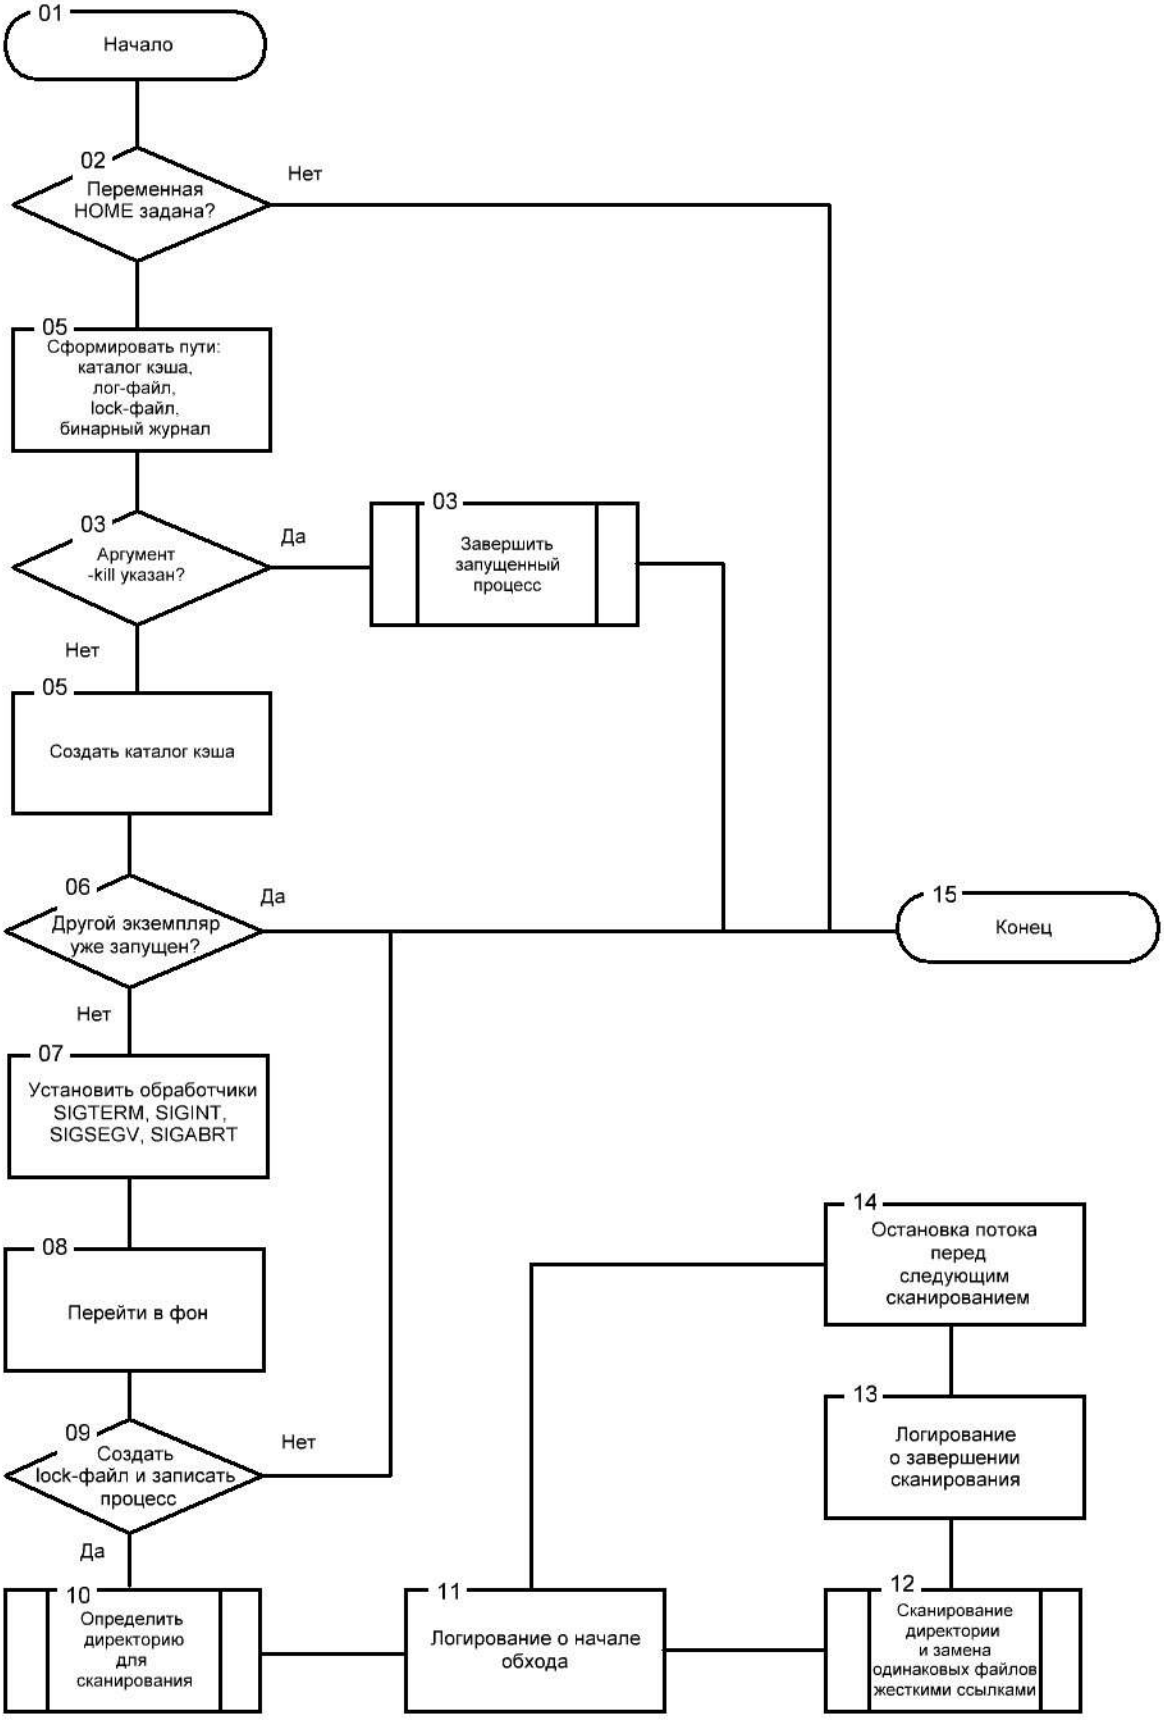

Изм	Лист	№ докум.	Подпись	Дата
Разраб.		Власов		
Провер.		Поденок		
Т. контр.				
Реценз.				
Н. контр.				
Утверд.				

ГУИР.250541.002 ПД1

Утилита контроля появления дубликатов в файловой системе
Схема функции main

Лит	Масса	Масштаб
У		

Лист	Листов

ЭВМ, гр. 250541

ПРИЛОЖЕНИЕ Б

(Обязательное)

Блок-схема алгоритма функции lookup_duplicate

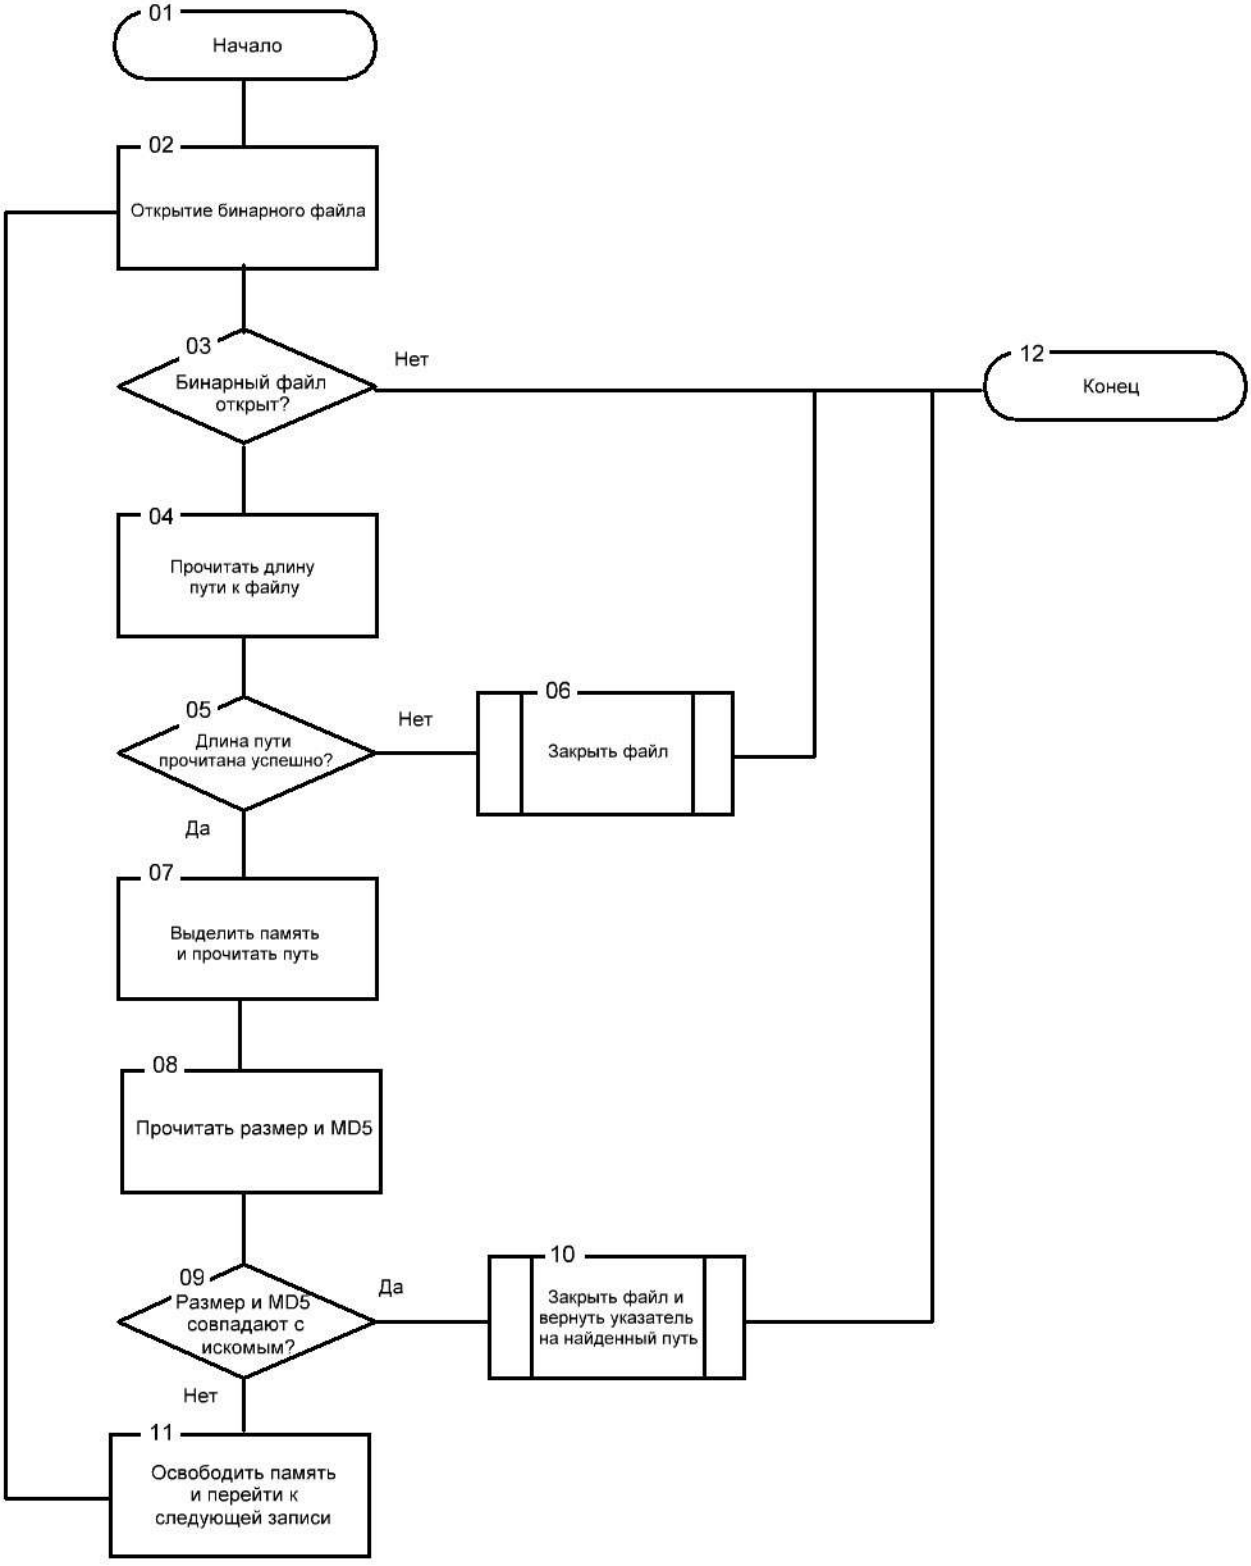

Изм	Лист	№ докум.	Подпись	Дата
Разраб.		Власов		
Провер.		Поденок		
Т. контр.				
Реценз.				
Н. контр.				
Утверд.				

ГУИР.250541.002 ПД2

Утилита контроля появления дубликатов в файловой системе
Схема функции lookup_duplicate

Лит	Масса	Масштаб
У		

Лист	Листов

ЭВМ, гр. 250541

ПРИЛОЖЕНИЕ В

(Обязательное)

Блок-схема алгоритма функции compute_md5

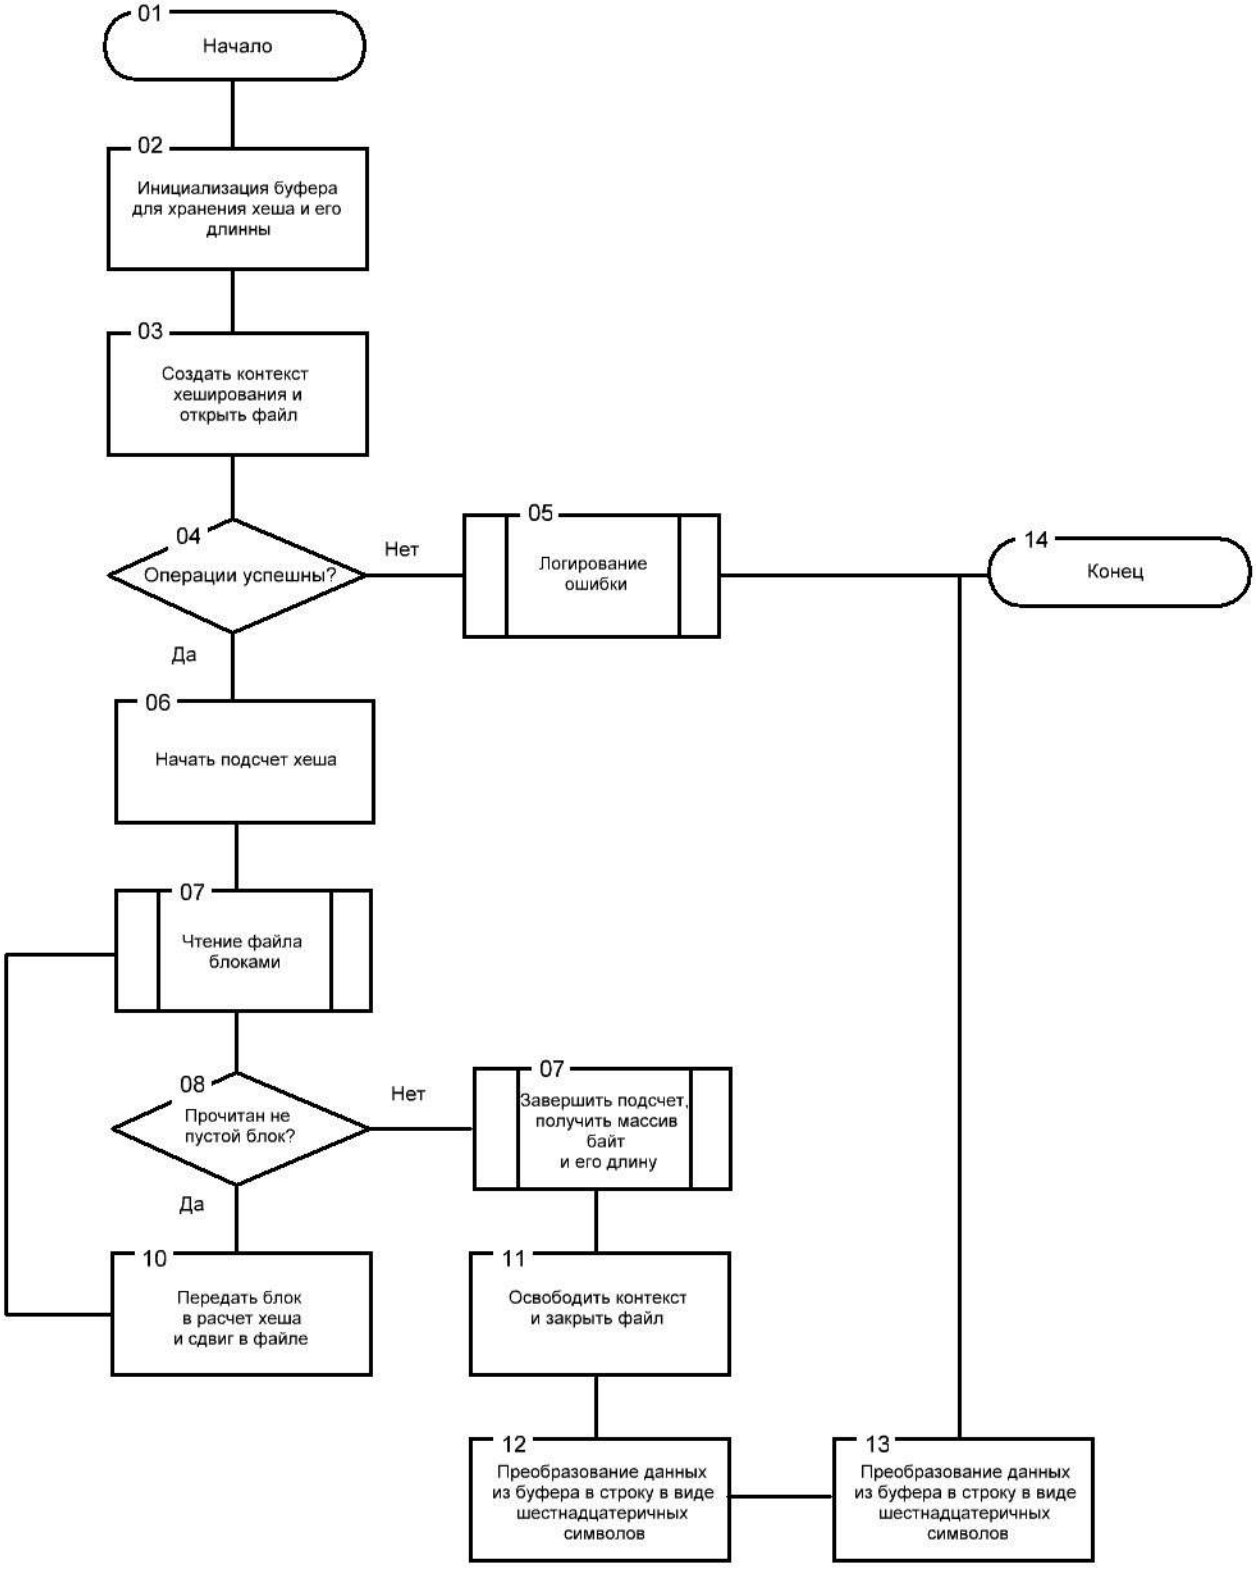

Изм	Лист	№ докум.	Подпись	Дата
Разраб.		Власов		
Провер.		Поденок		
Т. контр.				
Реценз.				
Н. контр.				
Утверд.				

ГУИР.250541.002 ПД3

Утилита контроля появления дубликатов в файловой системе
Схема функции compute_md5

Лит	Масса	Масштаб
У		

Лист	Листов

ЭВМ, гр. 250541

ПРИЛОЖЕНИЕ Г

(Обязательное)

Ведомость документов

Обозначение	Наименование	Примечание
	Текстовые документы	
ГУИР.250541.002 ПЗ	Пояснительная записка	29с
	Графические документы	
ГУИР.250541.002 ПД1	Блок-схема алгоритма функции main()	А4
ГУИР.250541.002 ПД2	Блок-схема алгоритма функции lookup_duplicate()	А4
ГУИР.250541.002 ПД3	Блок-схема алгоритма функции comute_md5()	А4

Изм	Лист	№ докум.	Подпись	Дата
Разраб.		Власов Р.Е.		
Провер.		Поденок Л.П.		
Т. контр.				
Реценз.				
Н. контр.				
Утверд.				

ГУИР.250541.002 Д1

Утилита контроля появления дубликатов в файловой системе с заменой их на жесткие ссылки и протоколирования фактов замены
Ведомость документов

Лит	Масса	Масштаб
У		
Лист	Листов	

ЭВМ, гр. 250541